

面向 AI 辅助学习的增量价值评价： 认知证据、误差传播与稳健决策

南行 缪雨轩 郭雨辰 徐问天 张梓涵
中国第一届数学建模黑客松 2026 年 9 月

摘 要

AI 辅助学习的过程评价需要区分任务提出的认知要求、学生实际展示的认知操作，以及撤去工具后的独立学习增益。本文以两学期平台日志为对象，建立“资料—认知测量—比较资格—指标合成—反例反馈—教学行动”的统一模型。将每条学生提问编码为任务要求和已展示贡献两个维度，以弃权保留证据不足；在固定随机子集上比较单快模型、双快模型和强模型复核流程，并用同题人工独立判断与 AI 推荐辅助复评考察判定边界。随后定义五项有界指标，以三套评价权重及标签、缺失和权重扰动计算条件范围，用主动攻击检查指标与教学目标的偏离。

对 3515 个真实学生回合的分析得到任务候选 1010 条、贡献候选 776 条，同回合双维共同非空仅 48 条。秋、春任务候选高阶比例为 19.52% 与 8.02%，但把未知回合纳入有界情景后，学期差的符号无法确定。同一 352 回合上，双快严格候选经强复核由 110 条变为 86 条；复核同时产生新候选和撤回候选。356 个有任务候选的学生一学期单元均缺有效 CTQ；完整 AIV 无点分，保守范围揭示了补充过程证据的必要性。

在 8 道诊断题的 16 组同题、同评审角色配对提交中，AI 推荐辅助复评的双人一致由 4/8 变为 6/8，后者含 2 题共同弃权；记录用时由 24.55 变为 19.41 人分钟，两名评审的变化方向不同，结果反映同题辅助条件下的观察差异。固定标签的合成反例中，工具堆叠使均衡分数增加 11.39 分，说明工具广度的评分作用需要机会条件和反例检验。现有日志支持过程诊断与条件范围；独立学习结局及有效回合时间的缺失，分别限制因果估计和滞后关联。评价链据此把结果转为可追溯的教学建议与数据补采要求。

关键字： AI 辅助学习；认知测量；选择性标注；复合指标；敏感性分析；教学决策

一、问题与研究思路

学生向 AI 请求“比较两个方案”，与学生自己完成比较，属于不同的认知证据。工具使用频次、生成答案的质量和学生离开工具后的学习表现，也处在不同的测量层面。认知投入框架强调可观察活动的差异，认知卸载与 AI 素养研究则提示工具使用需要结合人的判断过程解释^[1-3]。因此，本文围绕一个问题展开：怎样把可核对的**过程证据**转成能够说明适用条件、经得起反例检验的**学习诊断**？

赛题的五个模块对应一条相互约束的研究链。A 从原文形成认知候选及其不确定性；B 确定候选能够支持的比较；C 将可用测量转成指标和条件分数；D 检验标签、权重及行为操纵能否改变结论；E 将稳定结论和不确定来源映射为教学行动。设原始记录和来源坐标为 (R, P) ，两维标签为 (L^T, L^C) ，可比较集合为 $\mathcal{P}$ ，指标为 x ，分数为 S ，则

$$(R, P) \longrightarrow (L^T, L^C, U_L) \longrightarrow \mathcal{P} \longrightarrow (x, U_x) \longrightarrow (S, U_S) \longrightarrow a. \quad (1)$$

U_L, U_x, U_S 分别保存标签、指标和分数的不确定性。D 的检验沿相反方向反馈：证据匹配问题修订 A 的标注条件，时间或样本选择问题缩小 B 的比较范围，刷分与权重敏感性修订 C 的解释及 E 的行动强度。




图 1 证据进入评价链，反例沿链反馈；每一环节向下游传递结果及适用条件。

本文的方法选择服务于上述接口。LLM 评审研究表明，提示设计、重复运行与文本攻击会改变判断^[4-7]；本文据此同时保留弃权、有效分母和复核来源。预测辅助推断可用概率抽取的参考标签校正群体均值，但收益依赖残差和抽样条件^[8-10]；本文将其作为校验资源配置的设计依据。教育效果研究将工具辅助表现与独立学习结局分开^[11-12]；本文相应把过程描述与因果目标分开建模。复合指标中的缺失、权重和排序不确定性按统一的可行范围处理^[13]。

二、资料、研究单位与选择机制

2.1 研究总体与来源连接

资料包含 2025 年秋季与 2026 年春季平台问答表，以及秋季智能体使用表。两学期问答表共 2770 行；按学期窗口、春季参与名册和文本可用性筛选后纳入 1225 行，其中

秋季 824 行、春季 401 行。排除条件存在重叠，筛选后的数量以实际交集计数。在这些行内按 Q/A 结构恢复 3522 个学生提问回合，其中 3515 个满足送评结构条件，构成本文的真实分析总体；另外 12 条合成控制仅用于流程检查。

回合、原始 CSV 行、会话和学生一学期是不同单位。每个回合保留源文件哈希、行号、字段内字符区间和片段标识。回合顺序由文本结构恢复，CSV 创建时间表示原始行的记录时间；二者均不直接给出逐回合发生时间或已经核验的会话相邻边。跨学期学生标识按学生一学期单元处理，未经身份连接验证的标识不作为纵向同一人。公开图表采用聚合结果，逐条文本与来源保存在授权私有资料中。

表 1 真实总体与两维最终候选的分母

学期	入选原始行	合格学生回合	任务候选	任务候选覆盖
2025 秋	824	2509	661	26.35%
2026 春	401	1006	349	34.69%
合计	1225	3515	1010	28.73%

2.2 可判定性是分析结果的一部分

记 O_i^T, O_i^C 为任务和贡献维度存在最终候选的指示， O_i^E, O_i^M 为会话边与工具字段满足定义要求的指示。任务候选仅占总体的 28.73%，因此候选中的层级均值回答的是“可判定文本表现出什么特征”。对有界目标量 Z ，有


$$\mathbb{E}[Z \mid O = 1] - \mathbb{E}[Z] = \frac{\text{Cov}(Z, O)}{P(O = 1)}. \quad (2)$$

当文本长度、表达方式或任务复杂度同时影响 Z 与可判定性时，候选分布便具有选择性。两学期候选覆盖相差 8.34 个百分点，比较均值前必须先检查两者究竟筛选了什么。弃权是证据不足的判断，分歧是有效判断未形成一致，技术失败是请求或输出不可用；三者对后续补采和人工处理的意义不同。

为量化可判定性对学期比较的影响，固定候选标签，让其余回合的潜在层级在 L1 至 L6 间任取。令总回合为 N 、候选数为 n 、候选层级和为 s 、候选高阶数为 h ，得到

$$\text{ABL}_{\text{raw}} \in [(s + N - n)/N, (s + 6(N - n))/N], \quad \text{HOT} \in [h/N, (h + N - n)/N]. \quad (3)$$

这是一种保留候选的条件构造，检查未知部分需要何种约束才能支持总体比较。秋、春候选任务的平均层级分别为 2.554 与 1.734，高阶占比分别为 19.52% 与 8.02%；候选春减秋为 -11.49 个百分点。扩展到全部合格回合后，两学期 HOT 分别在 [5.14%, 78.80%] 与 [2.78%, 68.09%] 内，春减秋范围为 [-76.01, 62.95] 个百分点。范围覆盖正、负方向，说明已知候选的学期差尚不足以确定总体过程差的方向。贡献维度的春减秋范围同样跨零 ([-80.74, 79.10] 个百分点)，因此后续 B 对两学期保留分层描述。



条件情景：蓝段将无候选回合取任意 L1-L6；橙点仅为候选子集。保持候选标签固定；范围不是置信区间。

图 2 任务维度的学期描述与未知标签范围。橙点为各学期候选集；蓝段允许所有无候选回合取 L1 至 L6，范围为条件情景。

三、 A：认知测量与 AI 辅助校验

3.1 两维标签、决策规则与共同样本比较

L1 至 L6 依次表示记忆、理解、应用、分析、评价、创造。任务标签 L^T 编码学生原文要求执行的操作；贡献标签 L^C 编码学生本人已经展示的操作。只提出一个分析问题可以提供任务维度证据，而贡献维度需要可见的分析内容。证据不足时输出 $\perp$ ，与 L1 分开记录。模型同时返回连续原文、判断理由和状态；逐字符引文匹配核验的是来源位置，语义层级由模型与人工分别判断。

两快模型独立处理全部 3515 回合。按学期、种子 26 预选 352 回合（秋季 251、春季 101）接受两强模型独立复核；另有 827 回合由分歧、失败或解析风险等条件进入风险复核。首次复核不提供快模型答案。比较流程时固定在相同 352 个随机回合上：单快流程接受单模型有效判断；双快流程按两模型规则形成候选；强复核流程按已执行的复核规则再形成结果。这样得到的是同一输入集合上覆盖、弃权与分歧的代价，而非把风险子集和全量简单比较。

设模型接受指示为 A_{im} ，覆盖为 $c_m = N^{-1} \sum_i A_{im}$ 。独立参考标签 Y_i 存在时，条件错误风险定义为

$$R_m = \frac{\sum_i A_{im} \mathbb{I}(\hat{L}_{im} \neq Y_i)}{\sum_i A_{im}}. \quad (4)$$

本次共同随机集保留模型之间的一致性与状态比较；没有以模型多数票构造式 (4) 中的独立参考。Cohen $\kappa = (p_o - p_e)/(1 - p_e)$ 使用共同非空配对，区间按学生整簇重抽样。共同弃权另列，避免以大量共同未知掩盖可判定部分的差异。

任务候选覆盖由单快的 36.36% / 40.34%，变为双快严格一致的 31.25% 和复核合




图 3 相同 352 个分层随机回合的流程比较。每条状态合计为 352；两快和强复核使用既定的不确定判断与失败回退规则。

表 2 共同随机集的状态计数；单模型候选不要求另一模型一致

维度	流程	候选	弃权	分歧	不确定	失败
任务	DeepSeek 单快	128	208	0	16	0
任务	GLM 单快	142	189	0	9	12
任务	双快严格一致	110	184	35	11	12
任务	强复核合并	86	129	122	12	3
贡献	DeepSeek 单快	101	251	0	0	0
贡献	GLM 单快	88	252	0	0	12
贡献	双快严格一致	64	246	30	0	12
贡献	强复核合并	52	261	38	0	1


并的 24.43%。相对双快，复核获得 7 条新候选、撤回 31 条候选；双方都保留候选的 79 条中有 4 条改标。任务分歧由 35 增至 122，表明新增判断使部分原来的一致不再成立。贡献候选由 64 变为 52，获得 13、撤回 25；共同候选 39 条中有 5 条改标。流程选择同时改变覆盖与候选组成，无法用单一候选率评定其准确性。

与随机层相对，827 个风险回合的任务候选由双快的 39 增至复核后的 98，获得 76、撤回 17。风险层包含更集中的初始分歧与失败，复核在这里主要增加可判定结果；随机层则主要减少候选。两种方向共同说明，复核的收益依赖路由所选问题。正文后续指标使用合并后的最终候选，风险层不与随机层合并估计总体误差率。

3.2 真实双维分布与层级解释

在完整的 3515 回合中，任务维度有 1010 个最终候选、1812 个一致弃权、604 个分歧、76 个不确定和 13 个技术失败；贡献维度分别为 776、2457、268、0 和 14。任务与贡献的覆盖分别为 28.73% 和 22.08%，贡献维度的一致弃权达到 69.90%。因此，平台保

留的学生文本对“提出了什么要求”的证据多于“实际完成了什么操作”的证据。两维候选必须分别描述；其覆盖差不能直接解释为学生认知水平的差距。



真实数据 · 3515 个回合；左图按各自候选分母，右图仅共同非空配对。候选标签不等于独立能力。

图 4 双维边际层级分布与同回合共同非空配对。左图各维按自己的候选分母；右图仅 48 个配对，颜色与数字表示回合数。

表 3 学期内候选描述；学生等权只平均该维至少有一个候选的学生—学期单元

学期	维度	候选回合	候选单元	平均层级	回合加权 HOT	学生等权 HOT
秋季	任务	661	257	2.554	19.52%	18.58%
秋季	贡献	621	190	2.953	37.84%	34.29%
春季	任务	349	99	1.734	8.02%	5.56%
春季	贡献	155	54	2.542	25.16%	22.57%

任务候选的 L2 占主导；贡献候选则有较多 L4。边际 HOT 分别为 15.54% 与 35.31%，但 1010 个任务候选与 776 个贡献候选并非同一组回合，不能据两均值之差推断认知提升。在 48 个同回合共同非空配对中，任务高于贡献 13 个、相同 29 个、低于贡献 6 个，任务减贡献的平均层级差为 0.375；仅 5 个配对满足“任务为 HOT、贡献非 HOT”。共同配对只占全部回合的 1.37%，支持的是局部双维对应关系。

表 3 同时改变加权单位：秋季任务 HOT 由回合加权 19.52% 变为学生等权 18.58%，春季由 8.02% 变为 5.56%。方向保持相同，但幅度变化表明较多候选回合的单元对回合加权结果贡献更大。贡献维度也有这种差异。群体报告因此同时呈现候选覆盖、回合统计和学生等权统计，并将“有候选”条件保留到结论中。

两快模型任务维度共同非空 1248 对，六级 $\kappa = 0.795$ ，学生整簇重采样 95% 区间为 [0.764, 0.826]；贡献维度共同非空 955 对， $\kappa = 0.644$ ，区间 [0.602, 0.682]。学生簇重抽样保留同一学生内部依赖；跨学生共享缓存仍产生簇间依赖，这部分未在区间中额外校正。贡献判断的分歧更大，与其需要额外识别“学生是否实际展示操作”的要求相符。该解释是一种与测量定义一致的观察，并未将两维差异分解为模型能力或任务难度的因


果作用。固定 40 回合的重复检查中，两快模型各有 39 个双有效配对，任务重复相同分别为 36/39、35/39，贡献均为 35/39；重复性为下游标签扰动提供了必要性依据。

3.3 独立判断到 AI 推荐辅助复评

人工小样本以判定边界诊断为目标。首轮收集 12 份独立提交；随后两名评审对固定的 8 道诊断题各独立提交一次，共 16 份。AI 将判断说明组织为“主要操作—对象或条件—证据—边界”四个部分；在同一 8 题上显示共同推荐后，两名评审再各提交 8 份。两阶段按评审和题目连接，形成 16 组提交配对。原始独立判断、推荐快照、辅助修改和记录用时分别保存；最终 4 份定点人工核验另行封存。

表 4 同题独立判断与 AI 推荐辅助复评；8 题、2 名评审

观察量	独立阶段	推荐辅助阶段
提交数	16	16
双人完全一致（含共同弃权）	4/8	6/8
双方均给出层级	7/8	6/8
双方共同弃权	0/8	2/8
HOT 一致（双方给层级）	4/7	5/6
六级 κ （双方给层级）	0.344	0.556
连续原文证据匹配	16/16	16/16
记录用时合计（人分钟）	24.55	19.41



真实人审·16 组配对提交；24.55 → 19.41 人分钟；辅助 6/8 含 2 题共同弃权。
同题重复、共同推荐和固定顺序；时间包括停顿，属于过程观察。

图 5 16 组同题、同评审配对提交。两名评审的记录用时变化方向相反；辅助阶段的 6/8 一致包括 2 题共同弃权。

评审 A 的记录用时由 14.46 降至 4.80 人分钟，评审 B 由 10.10 升至 14.62 人分钟。合计减少 5.14 人分钟掩盖了个体方向差异；计时还包含停顿，因此保留逐角色数值比只报告一个效率比例更有信息。辅助后的 6 题一致中，4 题给出相同层级、2 题共同弃

权，显示校准部分来自对证据不足边界的共同认识。

原独立阶段的 4 道分歧题在辅助阶段形成一致，但有 2 道原先一致的题转为分歧，其中一题跨越 L3/L4 的 HOT 边界。13/16 份辅助标签与推荐相同，9/16 份的标签、证据和理由逐字相同；这说明推荐实际进入了判定过程，也说明共同推荐会改变评审间依赖关系。人工先判断后再看建议仍可能受锚定影响^[14-15]。故表 4 描述的是小样本同题辅助复评：题目熟悉、填写减少和推荐锚定均可能参与观察差异。末轮 4 份核验保留其辅助裁定身份，未回写两阶段的一致性分母。

这项探索对 A 与 C 的直接反馈是：判断协议必须同时呈现层级依据和不可判定边界；三阶分组 L1-2、L3-4、L5-6 的一致仍可能掩盖 HOT 所使用的 L3/L4 分界。因此，群体报告保留六级分布、HOT 与共同弃权，个体建议优先回查能改变行动的边界分歧。

四、 B：可比性、过程关联与增量目标

4.1 从已观测对象定义估计目标

模块 A 输出的是筛选后的认知候选。B 首先检查学期、课程、工具机会、学生组成与时间信息，确定这些候选支持何种比较。秋季与春季的任务候选覆盖分别为 26.35% 和 34.69%；春季工具身份字段不可直接核实。由此，两学期的原始分布差同时混合了任务内容、可判定性与观测机会差异。本文保留学期内描述以及共同定义下的分布比较，将其解释为日志的过程特征。

若研究 AI 对独立学习的增量，设事前定义的干预为 $T_i \in \{0, 1\}$ ，共同量尺、撤去工具后的潜在结果为 $Y_i(t)$ ，目标量为

$$\tau_{\mathcal{P}} = \mathbb{E}[Y_i(1) - Y_i(0) \mid i \in \mathcal{P}]. \quad (5)$$

识别需明确干预版本、时间零点、前测基础 X 、课程条件 C 和工具机会 A ，并满足一致性、条件交换性 $(Y(1), Y(0)) \perp T \mid X, C, A$ 与共同支持等条件^[16]。对照、失访和支持集可作资料诊断；未测混杂的影响仍需敏感性分析^[17]。

4.2 实际资格检查与未识别来源

资格检查使用 3515 个真实回合，其中 1010 个任务候选；可用逐回合时间戳为 0，严格前瞻关联的合格记录为 0、学生簇为 0。CSV 创建时间虽存在，其语义不支持回合发生顺序；因此本次没有估计回归系数，设计矩阵检查止于样本资格门槛。独立学习结局、无 AI 可比对照和处理前基础也未出现在所分析资料中。

可执行的过程关联以更早的候选历史预测更晚的任务或贡献候选。对回合 t ，令

$n_{i,<t}$ 为严格较早且可判定的回合数, $H_{i,<t}$ 为其中 HOT 比例, 可考虑

$$Z_{it} = \beta_0 + \beta_1 \log(1 + n_{i,<t}) + \beta_2 H_{i,<t} + \gamma_{\text{term}} + \eta \text{time}_{it} + u_{it}, \quad (6)$$

并按学生一学期单元聚类。 $n_{i,<t}$ 只计入可判定历史, 解释为标签可见的过程累积; 它不等于全部 AI 使用量。设计门槛为至少 100 条具有前序历史的记录、30 个学生簇及满秩设计矩阵。门槛用于阻止结构上无法估计的拟合, 不构成统计功效保证。由于本次逐回合时间不可用, 式 (6) 停留在已定义而未获得合格样本的过程模型。

对独立学习增量, 结局缺失具有更强的限制。

命题 4.1 (独立结局缺失下的不可识别性) 若资料只含使用记录 T 、问答日志 R 与课程/学期信息 C , 且没有经验证的 $R \mapsto Y$ 测量关系, 则 τ_P 不能由这些观测变量点识别。

证明. 固定任意观测分布 $P(T, R, C)$ 。第一种机制令 $Y(0) = Y(1) = 0$; 第二种机制令 $Y(0) = 0, Y(1) = 1$ 。两者对观测资料给出完全相同的分布, 目标效应却分别为 0 与 1。因此观测资料不能唯一确定该效应。其他有界结果尺度可取两个不同常数作同样构造。 $\square$

该结论给出后续采集的优先顺序: 独立前后测及共同锚定任务用于确定结果尺度, 处理前基础和工具机会用于建立比较人群, 逐回合时间和核验会话边用于过程动态分析。人工标签复评衡量的是标注过程, 不是学生学习前后测。B 将这些资格检查传给 C, 使过程指标与学习效应保持不同的解释对象。

五、 C: 有界指标与真实条件范围

5.1 五项指标的定义与性质

对学生 i 在固定学期窗内的 $n_i > 0$ 个任务候选, 记层级为 $L_{ij} \in \{1, \dots, 6\}$, 六级经验分布为 p_i 。平均层级与高阶占比定义为

$$x_i^{\text{ABL}} = \frac{n_i^{-1} \sum_j L_{ij} - 1}{5}, \quad x_i^{\text{HOT}} = n_i^{-1} \sum_j \mathbb{I}(L_{ij} \geq 4). \quad (7)$$

ABL 反映整体层级, HOT 关注分析及以上的份额; 二者来自同一标签, 相关性在合成中保留。

令 E_i 为经核验的同一会话内相邻学生回合边, 边端点为 e^-, e^+ 。当 $|E_i| > 0$ 时, 认知跃迁指标为

$$x_i^{\text{CTQ}} = \frac{1}{2} + \frac{\sum_{e \in E_i} (L_{e^+} - L_{e^-})}{10|E_i|}. \quad (8)$$

该值衡量净方向, 升降相抵会隐藏探索路径, 故具备边资料时还需报告上升、下降和持平边。无有效边时 CTQ 未定义。

预设教学目标分布 $q = (.10, .15, .20, .25, .20, .10)$ ，以总变差定义分布贴合度：

$$x_i^{\text{DHI}} = 1 - \frac{1}{2} \sum_{k=1}^6 |p_{ik} - q_k|. \quad (9)$$

q 代表课程设计偏好。提高某一个层级未必增加贴合度，过量集中于任一级都可能远离目标。针对低层过量的非对称敏感性方案为

$$d_a(p, q) = \sum_{k=1}^5 [2\{F_p(k) - F_q(k)\}_+ + \{F_q(k) - F_p(k)\}_+], \quad (10)$$

$$x_i^{\text{DHI}_a} = 1 - d_a(p_i, q)/M(q), \quad M(q) = \max_{j=1, \dots, 6} d_a(e_j, q).$$

F 为累计分布，2:1 惩罚比作为明示偏好参与扰动。若工具身份完整， m_i 为实际不同工具数，工具广度为

$$x_i^{\text{MAB}} = \min\{1, \log(1 + m_i)/\log 5\}. \quad (11)$$

工具身份缺失对应未知，原始 m_i 与课程可用工具数同时进入解释。

命题 5.1 (有界性与边集合稳定性) 五项归一指标在各自定义域内属于 $[0, 1]$ 。CTQ 在有效边集合固定时按边数加权分块保持不变；删除原边的比例为 $r < 1$ 且保留非空边集时，新旧 CTQ 的差至多为 r 。非对称 DHI 当且仅当 $p = q$ 时取 1。

证明. ABL 由 $[1, 6]$ 线性映射，HOT 是比例。CTQ 为每条边分数 $1/2 + (L_{e^+} - L_{e^-})/10 \in [0, 1]$ 的平均，故分块加权不变；删除边后原均值为 $(1 - r)\mu_{\text{keep}} + r\mu_{\text{drop}}$ ，差不超过 r 。总变差不超过 1。 $d_a(\cdot, q)$ 为凸函数，由 $p = \sum_j p_j e_j$ 得 $d_a(p, q) \leq \sum_j p_j d_a(e_j, q) \leq M(q)$ ；各累计差为零等价于 $p = q$ 。MAB 经截断位于 $[0, 1]$ 。□

5.2 合成偏好与部分观测

给定五维完整向量 x_i ，定义

$$S_i(w) = 100w^T x_i, \quad w_k \geq 0, \quad \sum_k w_k = 1. \quad (12)$$

使用表 5 的三套预设偏好。它们分别强调均衡、高阶占比和过程跃迁；在没有独立学习结局时，权重表达评价取向。

实际学生一学期共 401 个单元，其中 356 个至少有一个任务候选，45 个没有任务候选。候选支持 ABL/HOT/DHI；257 个单元满足 MAB 的字段条件，其余 99 个候选单元位于工具身份缺失的春季。有效会话边尚未核验，CTQ 可计算数为 0，完整 AIV 可计算单元数为 0，点分保持缺失。可计算子指标及缺失原因共同保留。

缺失正权重指标时点分保持空值。对情景范围，则允许未观测但有界的指标在 $[0, 1]$ 内变化。以已知 ABL/HOT/DHI、CTQ 缺失而 MAB 已知的单元为例，仅 CTQ 未知就使

表 5 三套合成权重

方案	ABL	HOT	CTQ	DHI	MAB
均衡	.20	.20	.20	.20	.20
高阶优先	.10	.50	.20	.15	.05
过程优先	.10	.20	.40	.25	.05

均衡、高阶、过程优先分数分别具有至少 20、20、40 分的可行宽度；MAB 同样未知时，下限宽度变为 40、25、45 分。它们由权重与定义域直接给出，提示会话边资料对“过程优先”的信息价值尤为明显。区间仍需联合考虑 ABL/HOT/DHI 的同源标签约束。

5.3 标签与权重扰动的求解及结果

设候选标签向量为 ℓ_i ，允许至多 $b_i = \lceil \epsilon n_i \rceil$ 个候选改标。由同一改标向量同时重算 ABL/HOT/DHI，定义

$$\mathcal{U}_i(\epsilon) = \left\{ g(\ell'_i, E_i, m_i) : \sum_r \mathbb{I}(\ell'_{ir} \neq \ell_{ir}) \leq b_i, \ell'_{ir} \in \{1, \dots, 6\} \right\}. \quad (13)$$

缺字段指标按明示边界扩展该集合。 ϵ 表示敏感性情景，不由模型自报概率替代真实错标率。以第 j 套权重为中心，逐项相对扰动后重新归一得到 $\mathcal{W}_j$ ，条件范围为


$$[L_{ij}, U_{ij}] = \left[\inf_{x \in \mathcal{U}_i, w \in \mathcal{W}_j} 100w^\top x, \sup_{x \in \mathcal{U}_i, w \in \mathcal{W}_j} 100w^\top x \right]. \quad (14)$$

它表示指定标签、缺失及权重情景下的可行分数，不是抽样置信区间。只有两对象在同一比较条件下满足 $L_{ij} > U_{kj}$ ，才可判为稳定高于；重叠时保留无法稳健区分的状态。

本次求解使用联合可行集的保守外包：将 ABL/HOT/DHI 的单项改标界分别截断至 $[0, 1]$ ，缺失指标取 $[0, 1]$ ，再枚举权重乘子的 32 个顶点。外包保留所有满足改标预算的真实组合，同时可能包含不能共同出现的组合，故其宽度与无法区分比例具有保守性。结果仅针对 356 个有任务候选的学生一学期单元，不外推到 45 个无候选单元。不改标且固定权重时，三方案范围宽度中位数分别为 20、20、40 分；仅加入权重 $\pm 10\%$ 扰动后，变为 24.33、24.14、45.18 分。可稳定区分对数分别从 6228、12575、0 降至 3651、9638、0。过程优先给缺失 CTQ 更大权重，因而真实资料不能支持该方案下的稳定区分。

名义 $\epsilon = .05$ 时， $\lceil \epsilon n_i \rceil$ 允许每单元改变 1 至 2 条标签，实际改标比例中位数为 50%、最大为 100%；这是候选稀疏条件下的“至少一条改标”检查。加入权重扰动后，三方案外包宽度中位数达到 68.11、68.18、77.27 分，可稳定区分对数为 0、1、0。 $\epsilon = .20$ 时三方案均为 0。结果说明，低候选数、结构缺失和外包的保守性共同限制个体分数用途；它不等价于测得了相应比例的标签错误，也不证明所有学生的真实能力相同。

固定 n 条中改变 s 条标签时，ABL、HOT、对称 DHI 的绝对变化均不超过 s/n ；固



条件情景：356 个有候选的学生×学期；权重 $\pm 10\%$ 。小样本向上取整可超过名义比例；非总体能力或真实排名。

图 6 真实候选单元上的条件分数外包范围。权重逐项相对扰动 $\pm 10\%$ ； ϵ 经向上取整转为改标条数，图中稳定区分限于同学期配对。

表 6 范围宽度和条件可区分性；356 个候选单元、37747 个同学期对

ϵ	权重扰动	方案	宽度中位数（分）	可稳定区分对数
0.00	0%	均衡	20.00	6228/37747
0.00	0%	高阶	20.00	12575/37747
0.00	0%	过程	40.00	0/37747
0.00	10%	均衡	24.33	3651/37747
0.00	10%	高阶	24.14	9638/37747
0.00	10%	过程	45.18	0/37747
0.05	10%	均衡	68.11	0/37747
0.05	10%	高阶	68.18	1/37747
0.05	10%	过程	77.27	0/37747
0.20	10%	均衡	69.62	0/37747
0.20	10%	高阶	68.29	0/37747
0.20	10%	过程	77.81	0/37747

定 $x \in [0, 1]^5$ 且两权重和均为 1，有更紧的权重界

$$|S(w, x) - S(w', x')| \leq 100 \sum_k w_k |x_k - x'_k| + 50 \|w - w'\|_1. \quad (15)$$

第二项利用权重差总和为零：正差与负差各占其 L_1 范数的一半。该外界便于检查数值求解，但联合可行集保留指标由同一标签生成的依赖；本次报告的外包范围放松该依赖，其保守性随结果一并解释。在这些条件情景下计算的宽度及重叠情况决定 E 采用具体反馈、敏感提示还是补采行动。

六、 D：主动检验与上游反馈

6.1 认知目标与可操纵分数的分离

攻击实验保持已知条件，单独改变一种输入，以定位失效机制。HOT 检验重复高阶记录对占比的影响，MAB 检验没有新增认知证据的工具堆叠，DHI 检验朝固定目标分布填充标签能否提高贴合分。攻击输入是合成计算性反例，其作用是检验指标性质。

表 7 指标攻击与条件反例；均为确定性合成构造

对象	控制条件与干预	数值结果	反馈位置
HOT	标签 [2,3,4,5] 复制一条 L5，保留同一认知内容	2/4 → 3/5，增加 0.10	依据来源去重，并保留真实重复练习事件
MAB	同一标签，工具数由 1 增至 4	均衡分增加 11.39	C：工具机会与评分权重
MAB 对照	对上述工具堆叠设 MAB 零权重	该攻击增分为 0	E：同时说明广度激励的取舍
DHI	按预设 q 构造标签分布	对称 / 非对称均为 1	依据课程信息设定 q ，解释限于分布贴合

对固定标签 [2,3,4,5]，仅将工具数从 1 堆到 4，均衡分数增加

$$100 \times 0.20 \left(1 - \frac{\log 2}{\log 5} \right) = 11.39 \text{ 分 (约)}. \quad (16)$$

工具饱和映射降低了进一步增加工具的边际收益，却仍奖励从 1 到 4 的堆叠。MAB 零评分权重的对照使此攻击增分为零，同时放弃对真实有益工具广度的奖励。据此，将 MAB 作为诊断信息，并结合可用工具机会解释其评分作用。

HOT 的问题回到 A 的研究单位与 C 的分母：相同学习事件重复导出应按来源去重，真实反复练习则保留事件身份；仅凭文本相同不足以区分两者。DHI 的问题回到教学设计： q 应由课程任务结构确定，达到 q 只表示分布贴合。CTQ 的问题回到 B 的会话资格：切分或复制改变边集时，固定边集的不变性命题不再适用。这样，每项失败都有明确的测量或定义修订位置。

既有文本检验使用 Claude Sonnet 5、Gemini 2.5 Pro 和 DeepSeek V4.1 Flash，在 7 个合成条件下每模型各调用一次，共 21 个输出。基线和认知动词注入条件均被三个模型标为 L2；文本重复条件依次为 L1、L2、L2，HOT 均未升高。加入实质分析内容的对照则均为 L4。该小规模观察说明，在所测试文本中，仅增加动词或重复没有产生高阶标签；它与表 7 中“直接重复已有高阶标签会提高 HOT”的计算结果对应不同环节：前者检验 A 的文本编码，后者检验 C 的聚合分母。原提示、模型组合和输入规模单列保存，其结果不并入 t3 的流程比较。

6.2 校验预算与真实证据的后续连接

群体均值校正需与抽样设计相容。若全体具有固定预测 f_i ，在互斥层 h 内以已知概率抽得参考值 y_i ，残差校正为

$$\hat{\mu} = \frac{1}{N} \sum_i f_i + \sum_h W_h \overline{(y - f)}_h, \quad \hat{V} \approx \sum_h W_h^2 \left(1 - \frac{n_h}{N_h}\right) \frac{s_{r,h}^2}{n_h}. \tag{17}$$

预算 B 、单次成本 c_h 下，整数分配最小化该方差并满足 $\sum_h c_h n_h \leq B$ ，连续近似为 $n_h \propto W_h \sigma_{r,h} / \sqrt{c_h}$ 。合成有限总体对照验证了该配置程序，数值与条件列于附录 A.4。当前 352 个随机复核的参考仍为模型，定向人工题又用于边界诊断，因此式 (17) 尚未产生真实总体的人工校正均值。此区分把已完成的流程比较与将来独立参考资源的配置连接起来。

七、 E：真实诊断与教学行动

模块 E 以 A 的可见证据、B 的比较资格及 C/D 的敏感性作为输入。已上线工作台 (<https://math.hnnu.team/>) 完成资料导入、来源定位、状态检查和确定性指标计算；报告将候选来源、覆盖与缺失一并呈现。既有模型候选注明批次来源，演示输入的指标计算与解释使用明确的可用字段。教师从群体分布定位任务设计和证据采集的不足，学生获得对应原文的一项可执行反馈，运营人员负责补足导致结果不可判断的字段。

表 8 真实结果、教学行动及适用条件

本研究的观察	对应教学行动	行动的适用条件
贡献候选 776/3515，贡献一致弃权 2457/3515	在请求答案后增加学生独立解释、比较依据或修订理由的留痕环节	将未展示视为证据缺口；新内容由学生实际完成
学期任务候选覆盖 26.35% 与 34.69%	分学期显示覆盖与分布，设置共同锚定任务后再比较	同任务、同机会、同标注口径，并检查选择性缺失
问题辅助复评一致 4/8 变为 6/8，仍含 HOT 边界分歧	使用四段判定卡；优先核查能改变教学反馈的边界题	保留独立与推荐辅助阶段身份，复核原文依据
真实 CTQ 缺失，完整 AIV 无点值	优先补充核验会话边；显示子指标与条件范围	新字段具备来源和时间语义，范围在同一情景下比较
工具堆叠产生 11.39 分合成增量	同时呈现工具机会、工具数及 MAB 的权重敏感性	检查广度是否对应新的认知证据与课程要求

以缺少会话边的输入为例，系统可以计算候选标签的 ABL/HOT/DHI，并返回 CTQ 的缺失原因及三权重的条件范围。教师因而能够选择补充会话证据或开展共同任务，学生仍能获得针对可见文本的反馈。由此，缺失状态参与下一步行动，而不被压缩为一个难以解释的低分。可复现实现把固定输入、分析代码与聚合图表连接到同一版本，运行入口见附录 A。

八、 讨论与结论

真实资料呈现三个相互关联的结果。首先，认知需求比学生贡献更容易在提问文本中形成候选，且两者都具有明显选择性；记录学生自己的解释过程，比进一步细化一个低覆盖候选均值更能改善测量对象。其次，AI 推荐辅助复评改变了双人一致和记录用时，也产生新的边界分歧；其价值在于让判断依据可检查，作用仍依赖题目、评审和推荐条件。再次，完整 AIV 的缺失和条件范围的宽度揭示了数据瓶颈，指标攻击则揭示了目标瓶颈：更多数据与更复杂合成都需要与明确的认知目标相连。

本文形成的闭环是：双维候选连同弃权进入测量；学期选择、时间和独立结局决定比较资格；有界指标将观测与缺失转成条件范围；扰动和攻击反馈到来源单位、权重及行动规则。其数学结果包括独立结局缺失下的不可识别构造、指标有界性、CTQ 的边集稳定性和标签/权重扰动界；实证结果包括共同随机集上的流程对照、双维与学期分布、同题人工辅助观察以及真实学生一学期的可计算性和敏感性。

主要限制集中在四处：日志只覆盖筛选后文本事件，候选可判定性与研究对象相关；模型可能共享错误，小范围定向人工复评未提供总体误差率；回合时间、核验会话边和部分工具字段缺失；课程目标分布及权重具有价值选择。对应的研究升级是概率抽取的独立参考、共同锚定任务、明确的过程时间与无 AI 独立结局。现阶段的教学使用据此定位于可追溯的过程诊断、边界复核和补采决策。

AI 使用声明。 AI 用于文献整理、代码与推导辅助、两维认知编码、推荐辅助复评及图文表达。批量测评、人工独立判断、辅助采纳和最终核验分别保存，团队负责公式、文献、结果解释与提交。工具身份、调用与采用过程详见附录 B。

参考文献

- [1] CHIM T H, WYLIE R. The ICAP Framework: Linking Cognitive Engagement to Active Learning Outcomes[J]. Educational Psychologist, 2014, 49(4): 219-243. DOI: 10.1080/00461520.2014.965823.
- [2] RISK O E F, GILBERT S J. Cognitive Offloading[J]. Trends in Cognitive Sciences, 2016, 20(9): 676-688. DOI: 10.1016/j.tics.2016.07.002.
- [3] LONG D, MAGERKO B. What Is AI Literacy? Competencies and Design Considerations[C]//Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems. ACM, 2020: 1-16. DOI: 10.1145/3313831.3376727.
- [4] Jiawei Gu, Xuhui Jiang, Zhichao Shi, et al. A Survey on LLM-as-a-judge[J]. The Innovation, 2026, 7(6): 101253. DOI: 10.1016/j.xinn.2025.101253.
- [5] Rajarshi Haldar, Julia Hockenmaier. Rating Roulette: Self-Inconsistency in LLM-As-A-Judge Frameworks[EB/OL]. 2025. <https://arxiv.org/abs/2510.27106>.

- [6] Yoshio Yamauchi, Taro Yano, M. Oyamada. An Empirical Study of LLM-as-a-Judge: How Design Choices Impact Evaluation Reliability[EB/OL]. 2025. <https://arxiv.org/abs/2506.13639>.
- [7] Yulai Zhao, Haolin Liu, Dian Yu, et al. One Token to Fool LLM-as-a-Judge[EB/OL]. 2025. <https://arxiv.org/abs/2507.08794>.
- [8] ANGELOPOULOS A N, BATES S, FANNJIANG C, et al. Prediction-Powered Inference [J]. *Science*, 2023, 382(6671): 669-674. DOI: 10.1126/science.adi6000.
- [9] ANGELOPOULOS A N, DUCHI J C, ZRNIC T. PPI++: Efficient Prediction-Powered Inference[EB/OL]. (2024-03-26). <https://arxiv.org/abs/2311.01453v2>.
- [10] Pranav Mani, Peng Xu, Zachary C. Lipton, et al. No Free Lunch: Non-Asymptotic Analysis of Prediction-Powered Inference[C]//*Proceedings of Machine Learning Research: Proceedings of the 43rd International Conference on Machine Learning*: vol. 306. PMLR, 2026.
- [11] BASTANI H, BASTANI O, SUNGU A, et al. Generative AI Without Guardrails Can Harm Learning: Evidence from High School Mathematics[J]. *Proceedings of the National Academy of Sciences*, 2025, 122(26). DOI: 10.1073/pnas.2422633122.
- [12] 和文斌, 赵帅, 阿不来提·瓦依提, 等. 基于生成式人工智能的人机协同学习更能提升学习成效? ——基于 20 项实验和准实验的元分析[J]. *开放教育研究*, 2024, 30(5): 101-111. DOI: 10.13966/j.cnki.kfjyyj.2024.05.010.
- [13] OECD, European Union, European Commission Joint Research Centre. Handbook on Constructing Composite Indicators: Methodology and User Guide[M]. OECD, 2008(2008-08-22). DOI: 10.1787/9789264043466-en.
- [14] Zana Bucinca, Maja Barbara Malaya, Krzysztof Z. Gajos. To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI in AI-assisted Decision-making[J]. *Proceedings of the ACM on Human-Computer Interaction*, 2021, 5(CSCW1): 188. DOI: 10.1145/3449287.
- [15] ASHKTORAB Z, DESMOND M, PAN Q, et al. Emerging Reliance Behaviors in Human-AI Content Grounded Data Generation: The Role of Cognitive Forcing Functions and Hallucinations[C]//*CHIWORK ' 25: Proceedings of the 4th Annual Symposium on Human-Computer Interaction for Work*. New York, NY, USA: ACM, 2025. DOI: 10.1145/3729176.3729179.
- [16] HERNÁN M A, ROBINS J M. Causal Inference: What If[M]. Boca Raton: Chapman & Hall/CRC, 2020.
- [17] Sizhu Lu, Peng Ding. Flexible Sensitivity Analysis for Causal Inference in Observational Studies Subject to Unmeasured Confounding[EB/OL]. 2023. <https://arxiv.org/abs/2305.17643>.

附录 A 研究对象、计算细节与仓库复现

A.1 主要符号与结果入口

表 9 主要符号及计算对象

符号	含义
R, P	原始资料及文件、行、片段、位置索引。
$L^T, L^C, \perp$	任务要求、已展示贡献与证据不足的弃权。
O^T, O^C, O^E, O^M	两维候选、核验会话边和工具字段的可用指示。
$Y(1), Y(0), \tau$	无 AI 独立测量的潜在结果与目标因果效应。
p_i, q, E_i	学生候选层级分布、预设课程分布和核验相邻边。
x_i, w, S_i	五指标、非负和为一的权重、完整条件下的点分。
$\epsilon, b_i, \mathcal{U}_i, \mathcal{W}_j$	名义改标参数、整数改标条数、联合指标及权重集合。

主结果为逐回合批次 t3。冻结清单位于

```
runtime/research/full-turns-v1-20260926T143225Z/t3/frozen/snapshot-manifest.json
```

其 SHA-256 为

```
7e885ceecf12a180349369ed9ddfc962ad71f1ea270f68b037a86a396430631d
```

聚合分析入口为 `results/final-analysis/summary.json`，其中保存输入哈希、分母、方法条件、分析代码哈希和图表索引。论文所用聚合段落与表格在 `paper/final_analysis_results.tex`；图表由实际分析结果绘制。源文件、结果与最终 PDF 的哈希由交付清单绑定，代码版本使用仓库交付说明中的固定提交。

A.2 来源、输出状态和统计分母

两学期 2770 条问答行经范围筛选得到 1225 行，在其中恢复 3522 个学生提问回合，合格文本回合 3515。结构异常的 7 回合保留来源，不进入模型统计。DOCX 正文、图片及转写另有来源清单，未经验证的跨文件身份与会话连接不参与本研究的统一计数。学生一学期表保留 401 个单元；只有具有任务候选的 356 个单元进入候选指标敏感性，其他 45 个单元保留无候选状态。

基础逻辑任务为 $3515 \times 2 = 7030$ ，有效输出 6929，失败 101；有效包括明确弃权。随机复核为 352 回合、704 个逻辑任务，其中有效 692；额外风险复核为 827 回合、1654 个逻辑任务，其中有效 1638。12 个合成控制产生 48 个有效基础/复核输出；两快模型各 40 个重复任务，共 80 个，其中有效 78。真实 API 尝试、重试、逻辑任务和真实学生样

本分别计数。相同输入仅在实验、模型、阶段、提示和参数完全相同时复用校验成功的响应；重复性检查不复用首次响应。

按维度先形成双模型状态：所需输出缺失记技术失败；两标签（含空值）不同记分歧；共同空值记弃权；任务维度共同非空但任一输出标为不确定时保留不确定；其余相同非空标签形成候选。已复核回合优先采用两强模型的候选或共同弃权；只有强复核技术失败、而双快已有候选或共同弃权时，回退双快结果。强模型之间的分歧继续保留。该规则逐条与封存最终状态核对，相同随机集流程比较使用同一套规则。

两模型六级一致性只用双方非空记录，三阶将 L1-2、L3-4、L5-6 合并。学生整簇重抽样次数为 2000，保留同一学生内部依赖；跨学生共享缓存造成的簇间依赖未在这些区间中额外校正。同模型重复、共享缓存与问题辅助复评均保留记录身份和来源。随机层与风险层分别列示，风险层用于定位难例，不能按其比例推断全体错误率。

A.3 敏感性计算的定义域

全回合未知标签范围固定所有最终候选，把其他回合分别赋予允许的最低与最高值。若总回合为 N 、候选数为 n 、候选层级和为 s 、候选高阶数为 h ，则

$$\text{ABL}_{\text{raw}} \in \left[\frac{s + N - n}{N}, \frac{s + 6(N - n)}{N} \right], \quad \text{HOT} \in \left[\frac{h}{N}, \frac{h + N - n}{N} \right]. \quad (18)$$

该构造假设未知回合具有潜在六级值，评价的是这一假设下的敏感性；它没有把弃权重新认定为已观测标签。春减秋范围采用春季下界减秋季上界及春季上界减秋季下界。

学生分数范围的对象是具有候选的学生一学期单元。允许改标条数取 $b_i = \lceil \epsilon n_i \rceil$ ，取 $\epsilon = 0, .05, .10, .20$ 。实现用 ABL/HOT/DHI 各自变化不超过 b_i/n_i 的区间，截断至 $[0, 1]$ ；缺失 CTQ/MAB 取 $[0, 1]$ 。这些边际区间的笛卡尔积是式 (13) 的保守外包，允许部分不能同时出现的指标组合。权重乘子为 $1 \pm .10$ ，枚举五项乘子的 32 个顶点后归一；对外包矩形在每个顶点求线性极值，得到外包范围。区间不重叠是稳定区分的充分条件；重叠可能来自实际不确定性，也可能来自外包的保守性。

同学期比较共 $\binom{257}{2} + \binom{99}{2} = 37747$ 对。严格大于对方上界并超过 10^{-10} 数值容差时计为可稳定区分。该计数不跨学期连接身份，也不形成真实能力排序。 $\epsilon = .05$ 时，向上取整后的改标比例中位数为 50%，最大为 100%；这反映多数单元候选很少。

A.4 预实验和合成计算对照

首问预实验的单位为 384 条文本，与正文逐回合总体不同。该预实验的双快共同非空任务配对为 210 对、157 个学生簇，六级 $\kappa = 0.823$ ，学生整簇 95% 区间为 $[0.750, 0.889]$ ；强复核子集共同非空为 50 对、49 簇， $\kappa = 0.646$ ，区间为 $[0.458, 0.802]$ 。由于输入粒度、复核选择和模型条件有差异，这些结果保留为流程探索记录。其逐题输出与失败记录在私有版本目录中单列。

有限总体合成实验取 $N = 400$ 、层规模 $[240, 120, 40]$ 、单位成本 $[1, 2, 3]$ 、总预算 150，重复 500 次。给定实验者已知的残差方差，整数动态规划得到分配 $[49, 37, 9]$ 。表 10 用于检查分配程序及方差公式，成本单位为合成单位。

表 10 相同预算下的合成参考标签配置

策略	分配 $[n_1, n_2, n_3]$	RMSE	名义 95% 区间覆盖
等量	[25,25,25]	0.0380	93.6%
按规模	[60,30,10]	0.0321	93.2%
已知方差 / 成本最优	[49,37,9]	0.0285	95.8%

另以 24 名合成学生、每人 8 条标签比较三套权重和平方根聚合，检查聚合选择是否改变分数。文本红队保留 7 个条件、3 个模型共 21 个输出，包含冗长、动词注入及复制答案等输入；该实验使用早期模型/提示条件，每条件每模型一次，不用于估计 t_3 的攻击成功率。

A.5 仓库入口与一条复现命令

代码、聚合数据、图表及运行说明见仓库：

<https://github.com/HNNUYUXUAN/nanxing-aiv>

复算时检出交付说明对应的固定版本，并核对聚合清单中的来源哈希。授权研究资料与公开聚合材料有不同复算范围。完成固定依赖安装后，在项目根目录运行

```
.venv/Scripts/python.exe scripts/reproduce.py
```

即可用聚合结果重绘研究图表并运行确定性演示样例。--authorized-inputs 在已具备授权原始资料时重建逐回合聚合分析，--notebooks 进一步执行研究 Notebook。具体输入、输出和运行回执见 docs/复现说明.md。模型 API 批次重跑与上述确定性复算分离；复算无需再次付费调用模型。

Python 依赖由 requirements-lock.txt 固定。论文使用仓库已有的多文件 XeLaTeX/Biber 工具链排版：

```
powershell -NoProfile -ExecutionPolicy Bypass `
  -File scripts/build_latex.ps1 `
  -Source paper/main.tex -OutputDirectory build/paper
```

正文与参考文献、附录分别计页。原始学生记录、研究标识、数据库及凭据仅保存在授权私有资料中；公开仓库提供聚合结果和合成示例。旧环境归档与研究包操作记录保存在内部文档中。

附录 B AI 使用、试错过程与人工采用

B.1 使用范围与责任

AI 辅助研究问题梳理、文献检索与摘录、程序开发、推导检查、候选认知编码、判定说明和图文表达。研究团队确定问题、假设、指标及解释，核对原文、公式和输出，并决定最终采用内容。批量测评由 Next 与 TokenDance 平台提供接口；Next 为赛事 Token 指南所列算力入口。

表 11 主要 AI 工具及实际用途

环节	工具与精确标识	用途
研究与实现	Codex, gpt-6-astra	问题和文献梳理、建模与代码辅助、论文与结果核对。
基础编码	DeepSeek V4.1 Flash, deepseek-v4.1-flash	独立判断任务与已展示贡献，输出连续原文、解释及弃权。
基础编码	GLM 5.3 Flash, glm-5.3-flash	相同输入和规则下的第二独立基础判断。
独立复核	Claude Sonnet 5, claude-sonnet-5	对固定随机与高风险子集作独立复核。
独立复核	GPT-6 Sol, gpt-6-sol	同一复核子集的第二独立判断。
说明性插图	ChatGPT 图像生成	依据团队提供的文字和技术关系生成说明图；团队核查内容。

模型身份由实际调用计划和记录核对。基础编码使用 TokenDance，复核使用 Next；早期三模型文本预实验另使用 Gemini 2.5 Pro (gemini-2.5-pro)。服务端细分版本以接口记录为准。本文定量图由聚合分析代码绘制，图像生成服务用于说明性材料。

B.2 从候选判断到人工采用的探索链

探索过程按输入、AI 产物、可见问题、核查与采用记录串联。文献阶段由 AI 提取研究设计、样本和结论，再逐页查回来源；曾在研究资料整合中发现 $8 + 43 + 55 + 44$ 被写为 118，经原文与算术核对修正为 150。AI 草稿与纠正依据分别留在文献 workflow 记录中，正文使用核定后的文献主张。

认知编码先在既有真实 6 题与合成 6 题上实际调用流程，检查双维标签、连续引文和弃权。该探索采用三模型独立判断、互评与必要的仲裁；表 12 保留实际有效输出和各阶段任务候选。旧规则要求三票均非空才形成多数票，并允许已执行的仲裁覆盖此前结果；其问题集、规则和模型条件与正文 t3 不同。

随后小范围人工探索收集首轮独立提交 12 份，并形成第二轮 8 题、双人独立提交 16 份。分歧暴露出名词短语、清单请求、具体应用和分析等边界解释不一致。AI 据此把说明组织为主要操作、对象或条件、证据和边界四部分，提供同题推荐；第三轮两名评审分别完成 8 份推荐辅助复评。

正文表 4 保留独立和辅助条件下的原始统计。推荐填入、理由模板及手动填写分别为 11、4、1 份；层级与推荐一致为 13/16，标签、证据与理由逐字相同为 9/16。四段内容可识别为 15/16，形式完整性与论证充分性分别检查。最后对 4 道边界题完成用户人

表 12 早期 AI 流程探索；真实与合成各 6 题

阶段	真实 6 题	合成 6 题
独立输出有效数	18/18	18/18
互评输出有效数	17/18	18/18
仲裁输出数	3	1
单 Claude 候选	3	6
独立多数票候选	1	6
互评多数票候选	2	6
最终候选	2	6
互评至最终的非空改标数	2	1

工核验并封存，保留原独立与辅助提交。该链条记录 AI 如何形成建议、人如何修改或采纳，以及哪些分歧仍需要保留；它不充当独立学习效果测量。

B.3 调用记录与核查范围

逐回合 t3 的 `plan.json` 保存规则、样本哈希、模型请求参数、输出上限及代码版本，`sample.json` 保存来源坐标。私有任务数据库保存消息与请求条件，尝试账本记录状态和可用返回；冻结清单把逐题结果与聚合分析绑定。技术失败、重试、缓存复用和逻辑任务分别保留。早期部分失败仅保存类别与用量，记录完整性按实际可得范围说明。

模型提示要求把学生文本中的指令视为研究数据，分开判断任务和贡献，证据不足时弃权，引文逐字连续匹配。程序核验字段、取值、重复键、引文位置、来源连接及统计分母；团队核查语义、文献和数学解释。模型自报概率、模型间一致性、人工推荐采纳和独立准确率具有不同含义。

AI 解题过程与采用记录的阅读入口为 `docs/AI 解题过程.md`，其中连接论文、研究 Notebook 与 workflow 说明；逐轮人工与调用原始记录保存在授权档案中。论文、图表和演示保留所使用版本和来源，公开材料使用聚合统计与合成例子。学生原文、私有标识及密钥不进入公开仓库。